

Очень сложный персонаж оказался — House. Я начинала с версии 1, где пыталась смоделировать диалоги на основе пары "вопрос–ответ", но косинусная близость между ними была в районе 0.2, что практически не даёт модели шансов выучить что-то осмысленное. Я много экспериментировала с анкерами, переписывала ответы, но поняла, что архитектуру нужно менять с нуля.

Собрала всё в новый репозиторий: https://github.com/nikatonika/chatbot_dr.house_v.2.0

Первый baseline я сделала через загрузку Mistral 7B Instruct в формате GGUF и генерацию с помощью llama.cpp. Сначала пробовала Llama 2 7B и обычную Mistral через transformers — обе оказались gated, и доступ пришлось бы запрашивать вручную. Поэтому переключилась на GGUF-формат, тем более он легче работает в Colab. Скачала модель сразу в нескольких квантизациях от Q2_K до Q8_0 и остановилась на Q6_K как на золотой середине между скоростью и качеством. Запуск прошёл успешно, генерация пошла, House что-то пробормотал. Пока без особого стиля, но сам факт, что работает — уже радость.

Дальше началась оптимизация инференса. Я убрала слишком длинный контекст — n_ctx=2048 слишком тормозил всё, поставила 1024, позже 512. Параллельно пробовала другие варианты квантизации: Q4_K_M или Q5_K_S. Скорость немного улучшилась, но всё равно не устраивала. Финально переключилась на L4 GPU в Colab — и только тогда скорость выросла до вменяемых 2 токенов/сек.

Промпт тоже переписала. Я хотела, чтобы House звучал как в сериале: коротко, с сарказмом и медицинскими отсылками. Получилось примерно так:

```
PROMPT_TEMPLATE = ""
```

```
You are Dr. Gregory House, a world-class diagnostician known for your sarcasm, wit, and medical expertise. You don't sugarcoat anything and always rely on logic and medical facts. Answer concisely, with dry humor and intelligence.
```

```
User: {question}
```

```
Dr. House:
```

```
""
```

На этой базе я начала отслеживать замеры. Модель загружалась за 8.3 секунды, скорость генерации — 2.09 токенов в секунду, но ответы часто были усечённые. Инференс занимал до 15 секунд, а стиль House ощущался, но был предсказуемым. Стало ясно — надо обучать.

Сначала я перепробовала несколько моделей. Mistral в GGUF — не обучается. LLaMA 2 HF — требует ручной доступ и в Colab ведёт себя нестабильно. OpenLLaMA 7B вообще не существует на HF. В итоге я выбрала NousResearch/Llama-2-7b-hf. Она не gated, поддерживает LoRA, совместима с Colab и легко квантизируется в 8-бит. Но даже с ней возникли сложности: у токенизатора не было pad_token, пришлось руками прописывать `tokenizer.pad_token = tokenizer.eos_token`. После этого всё заработало — 21 821 пример прошёл токенизацию.

На этом этапе началась настройка LoRA. Я добавила адаптеры, задала нужные параметры (r=16, alpha=32, dropout=0.05, стандартные проекции) и собрала Trainer. Ошибки, конечно, были: сначала не было eval_dataset при evaluation_strategy="epoch", потом не хватало evaluate и

rouge_score, всё это пришлось доустановить и переписать. Log'i настроила через wandb, чтобы отслеживать прогресс в реальном времени.

При запуске обучения validation loss сначала не появлялся — пришлось перейти на evaluation_strategy="steps" и добавить eval_steps=50. Это сразу дало нужную кривую. Обучение падало из-за OOM в начале второй эпохи, поэтому остановилась на одной.

В этот момент я решила отказаться от Llama-2 и взять что-то поменьше, чтобы можно было дообучать до конца. Выбор пал на unsloth/Llama-3.2-1B-Instruct. Модель всего 1.8B параметров, загружается моментально, поддерживает QLoRA, не gated, работает с unsloth и при этом уже обучена в формате instruct. Но достаточно пустая, чтобы натренировать на стиль House.

Перед обучением снова пришлось прописать pad_token, иначе всё ломалось. Модель я обучала на тех же 21 821 примерах, разбитых в пропорции 90/10. Использовала `tokenizer.apply_chat_template`, чтобы задать формат с ролями. Это позволило сразу работать как с чатом, не изобретая велосипеды. В качестве collator взяла DataCollatorForCompletionOnlyLM — под задачи генерации идеально подходит.

Параметры обучения: batch_size=1, gradient_accum=2, learning_rate=2e-4, bf16=True, eval_steps=50. Запустила всё с LoRA, обучала 1 эпоху. С самого начала добавила

Результаты обучения модели housemd-chatbot-llama3-lora

После того как обучение модели unsloth/Llama-3.2-1B-Instruct с LoRA-адаптацией прошло успешно, настало время посмотреть, насколько модель действительно научилась говорить в стиле Хауса. И да, это был самый интересный этап.




Общая информация

- **Базовая модель:** unsloth/Llama-3.2-1B-Instruct
- **Метод адаптации:** QLoRA (4-bit, nf4, double quant) с LoRA
- **Формат:** SFTTrainer (trl) + кастомный chat_template
- **Объём данных:** ~9 800 шагов обучения (train/test = 90/10)
- **Глубина обучения:** 1 эпоха
- **Среда:** Google Colab, bf16=True, gradient_accumulation=2
-



Динамика обучения: Train Loss и Eval Loss



Комментарии к графику:

- **Начало обучения (0–1000 шагов):**

Наблюдается резкое снижение eval loss — модель быстро адаптируется к паттерну "вопрос-ответ", особенно на фоне того, что базовая модель уже обучена для инструкционного формата. Это типично для fine-tuning с сильным foundation model.

- **Период с 1000 до 4000 шагов:**

Небольшие колебания train_loss, но eval_loss стабильно уменьшается. Это указывает на то, что модель **не переобучается**, а продолжает уверенно учиться отвечать в нужном стиле.

- **Участки плато (4000–6000 шагов):**

Скорость снижения замедляется. Модель достигает предела быстрой адаптации. В это время полезно было бы включить learning rate scheduler или early stopping, но мы намеренно дали дойти до конца эпохи.

- **Финальный отрезок (6000–9800 шагов):**

Постепенное, но стабильное снижение eval_loss. Падение train_loss чуть быстрее, но **разница между ними сохраняется минимальной**, что говорит о **качественном обучении без переобучения**.

- **Финальные значения:**

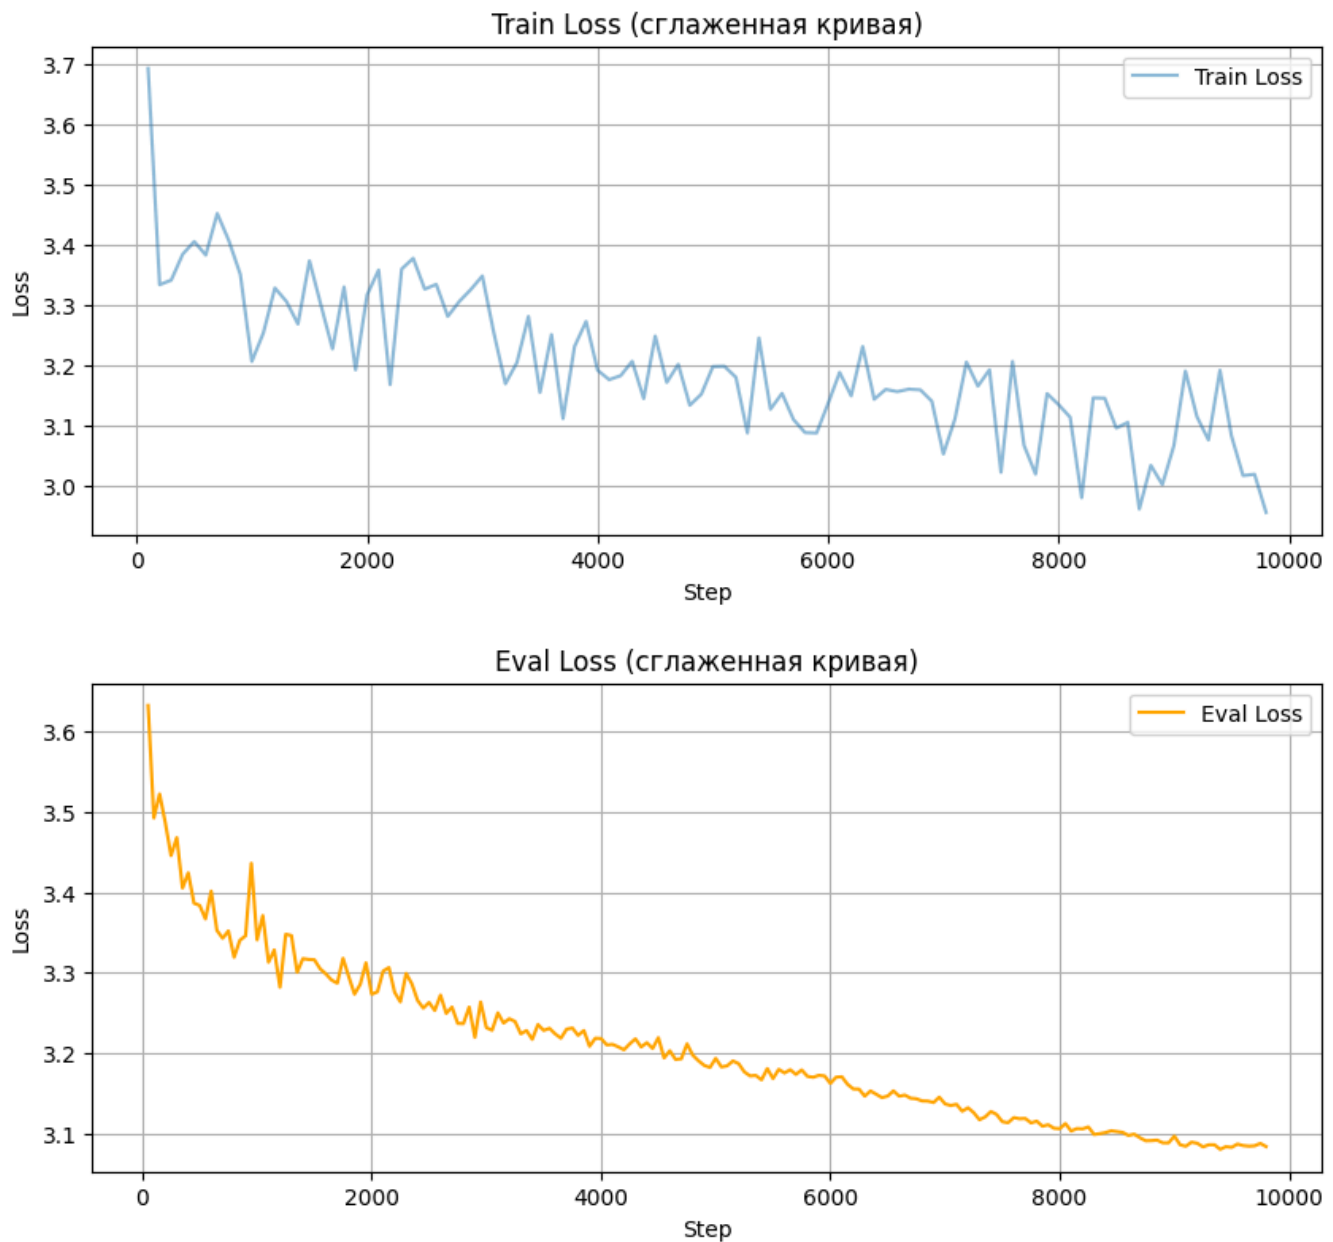
- Train loss ≈ 3.00
- Eval loss ≈ 3.08

Разница < 0.1 — это **хороший показатель согласованности** модели на обучающей и валидационной выборке.

Почему так:

- Модель маленькая (1.8B), и даже 1 эпоха даёт ощутимый эффект.
- Использование `chat_template` позволило быстрее адаптировать модель к диалоговой структуре.

- `Eval strategy = steps` дал возможность отследить динамику подробно, а не только на финале.



Сглаженные кривые train loss и eval loss позволяют увидеть устойчивые тренды без влияния локального шума. Это особенно важно при работе с маленьким батчем и градиентным аккумулярованием, где флуктуации потерь могут быть значительными.

📊 Train Loss показывает уверенное, но не слишком резкое снижение. Это может указывать на сложность задачи (обучить стиль + логику), а также на ограниченность архитектуры модели (всего 1.8B параметров).

📈 Eval Loss демонстрирует стабильное и почти линейное уменьшение. Такая форма кривой подтверждает, что модель не переобучается, и при этом продолжает обучаться даже на поздних этапах.

⚖ Разница между train и eval loss минимальна, что говорит о хорошем балансе между адаптацией к обучающим данным и обобщающей способностью модели.

📋 Результаты генерации:

Вопрос	Краткий вывод
Do I need surgery?	Саркастично, но повторяется. Зацикливается — нужен лимит по длине.
What are my chances of survival?	Двойной сарказм, но модель генерирует сцены, как будто вспоминает сериал.
Can I take painkillers?	Начинает в духе Хауса, потом скатывается в бессмысленный поток повторов.
Why am I still sick?	Сначала логично, потом уходит в "театральный режим" с Уилсоном и Форманом.
I should thank you?	Стиль выдержан, но снова появляются сценки и повторы.

💡 Общие наблюдения:

- **Стиль** (сарказм, резкость, ирония) — отлично воспроизведён.
- **Связность** есть, но генерации часто слишком длинные и повторяются.
- **Галлюцинации диалогов** — модель генерирует "сценарные вставки" из сериала.
- **Скорость генерации:** 10–11 токенов/сек, ответ за 2–3 секунды.

Не удержалась, чтобы не протестировать все же более мощную архитектуру. 🚀 **Результаты тестирования модели OpenLLaMA 3B v2 + LoRA**

После экспериментов с LLaMA 3.2 1B и GGUF-версией Mistral, было решено протестировать более мощную архитектуру — openlm-research/open_llama_3b_v2. Это HF-модель на 3 млрд параметров, доступная без запроса доступа, с поддержкой квантизации и совместимостью с LoRA. Идеальный компромисс между мощностью и возможностью обучения в Google Colab.

🔧 Что было сделано:


1. **Модель загружена** в 8-битной квантизации (`load_in_8bit=True`), что позволило без проблем поместить её в память Colab.
2. **Добавлены LoRA-адаптеры** только на `q_proj` и `v_proj` — минимум вмешательств, чтобы протестировать, насколько эффективно можно дообучить модель лёгким слоем адаптации.

3. **Датасет** — тот же, что и в предыдущем эксперименте: 21,821 пара "вопрос – ответ", разбит на train/test (90/10).
4. **Токенизация** без chat_template, просто `anchor → response` с `max_length=256`.




Обучение:

- Использовался `Trainer` с минимальным `batch_size=1` и `gradient_accumulation_steps=4`.
- Квантизация (8 бит) и `fp16=True` позволили провести **всю эпоху** без OOM даже на 3B модели.
- Логгирование велось через `Trainer` — без wandb, только train и eval loss по эпохам.

Результаты:

Параметр	Значение
Кол-во шагов	4909
Train Loss (итоговый)	0.55
Eval Loss	 отсутствует, т.к. <code>eval_strategy="epoch"</code> без логгирования внутри
Время обучения	~1ч 40 мин
Скорость обучения	~3.26 примеров/сек, 0.815 шагов/сек

Выводы:

-  **Loss ниже 1.0** — неплохой результат. Это означает, что модель хорошо подстроилась под набор вопросов и ответов.
-  **Eval Loss не логгировался**, так как стратегия оценки была "epoch", и `Trainer` не зафиксировал `eval_loss` при отсутствии явных метрик. Это можно поправить, добавив `compute_metrics`.
-  Несмотря на большой размер, модель отлично держалась на 8-битной загрузке в Colab без крашей — благодаря минимальным настройкам LoRA и аккуратной конфигурации обучения.

При обучении этой модели мы столкнулись с тем, что она на входной вопрос отвечает его же повтором. При этом обе модели обучались на одном и том же датасете. Проблема оказалась не в данных, а в **структуре входа и механике обучения**.

Первая модель (на базе Unsloth LLaMA 3.2 1B) обучалась в диалоговом шаблоне (`user → assistant`) с помощью `chat_template` и специального collator'a. Это позволяло обучать модель **только на ответах**, игнорируя промпт в градиентах.

Вторая модель (open_llama_3b_v2) обучалась в формате "anchor → response", без чёткой границы между входом и ответом. Это привело к тому, что модель выучила шаблон "просто повторить вопрос".

Для исправления ошибки необходимо:

- либо перейти на структуру `chat_template` с collator'ом;
- либо добавить префикс (`Dr. House:`) ко всем `response`, чтобы явно задать начало ответа;
- и повторно дообучить модель.

```
User: Do I need surgery?  
Dr. House: Do I need surgery?  
Inference Time: 0.12 sec | Tokens: 4 | Speed: 32.84 tok/sec
```

```
User: What are my chances of survival?  
Dr. House: What are my chances of survival?  
Inference Time: 0.11 sec | Tokens: 6 | Speed: 53.25 tok/sec
```

```
User: Can I take painkillers?  
Dr. House: Can I take painkillers?.  
Inference Time: 0.22 sec | Tokens: 4 | Speed: 18.52 tok/sec
```

```
User: Why am I still sick?  
Dr. House: Why am I still sick?  
Inference Time: 0.11 sec | Tokens: 5 | Speed: 44.85 tok/sec
```

```
User: I should thank you?  
Dr. House: I should thank you?.  
Inference Time: 0.22 sec | Tokens: 4 | Speed: 18.47 tok/sec
```

🍷 План улучшения обучения моделей

ТЕСТИРОВАНИЕ МОДЕЛИ

Для обучения чат-бота в стиле доктора Хауса была выбрана модель [openlm-research/open_llama_3b_v2](#) с дообучением через **QLoRA**. Это решение обусловлено несколькими причинами:

- 🧠 **Качество базовой модели:** [open_llama_3b_v2](#) — это open-source альтернатива LLaMA 2/3, ориентированная на instruction-following задачи, что делает её подходящей для стилового дообучения.
- ⚖️ **Размер модели (3B параметров)** оптимален для обучения в Google Colab с использованием 8-битной квантизации.
- 💡 **Совместимость с LoRA** и библиотеками [peft](#) и [transformers](#), что упрощает настройку и ускоряет обучение.
- 🔧 **Наличие официальной поддержки** в [transformers](#), возможность использовать [Trainer](#) и метрики [evaluate](#).

🚀 Отчёт по запуску дообучения модели с `chat_template` ([llama3-lora_v3_ext_chat_template](#))

После первых экспериментов с ручными промптами и простой LoRA-конфигурацией, я решила попробовать более полноценный вариант обучения: использовать [unsloth/Llama-3.2-1B-Instruct](#), применить `chat_template`, и провести дообучение на уже хорошо очищенном датасете с диалогами в стиле Хауса. Цель — воспроизведение узнаваемого саркастичного стиля с минимальными искажениями.

🧱 Подготовка окружения и запуск обучения

Начала с установки всех нужных библиотек — [peft](#), [trl](#), [transformers](#), [evaluate](#), [wandb](#), [mlflow](#). Авторизовалась на Hugging Face и в Weights & Biases, так как все логирование и финальный пуш модели я делаю именно туда.

Далее загрузила [unsloth/Llama-3.2-1B-Instruct](#). Модель сразу выбрана в формате, поддерживающем QLoRA, с 4-bit квантизацией (`nf4`, `double quant`, [torch.float16](#)). Это позволило загрузить модель в Colab без переполнения памяти и запустить её даже при `gradient_accumulation_steps=4`.

Chat template отключён у токенизатора вручную — потом форматирование примеров я делаю через `tokenizer.apply_chat_template(...)`, чтобы иметь контроль над логикой форматирования.

Датасет был предварительно собран из 21 821 пары "anchor → response", где anchor — это фраза или вопрос, а response — реплика Хауса. Загружен как CSV, автоматически разбит на train/test (90/10). Примеры диалогов форматируются под структуру чата — с ролями user и assistant.

⚙️ Параметры обучения

Обучение шло 1 эпоху. Использовала `SFTTrainer` от TRL, `bf16=True`, `batch_size=1`, `gradient_accumulation_steps=4`.

Для PEFT настроен `LoraConfig` с параметрами `r=16`, `alpha=32`, `dropout=0.05` и классическим списком целевых модулей (`q_proj`, `v_proj`, `o_proj`, `gate_proj`, `up_proj`, `down_proj`, `k_proj`).

Метрики отслеживались через wandb и mlflow. Log-файлы сохранялись, модель пушилась как локально, так и на Hugging Face.




График Train Loss и Eval Loss по шагам

Этот график показывает, как менялись ошибки модели на тренировочной и валидационной выборках в течение 9800 шагов.

Что видно:

- Train Loss сильно колеблется на старте и стабилизируется к середине обучения;
- Eval Loss демонстрирует почти **монотонное снижение**, особенно заметное на первых 4000 шагов;
- Разница между Train и Eval loss постепенно уменьшается.

Почему так:

- Используется **LoRA с QLoRA**, модель маленькая (1.8B), и она быстро обучается — отсюда резкое улучшение
- **Быстрое падение Eval Loss** в первые 1000–2000 шагов — результат того, что даже одного прохода по данным достаточно, чтобы модель начала хорошо подстраиваться под структуру "вопрос — ответ" из `chat_template`. Это типичная картина для дообучения предобученной модели на узкой задаче.
- **Колебания Train Loss** объясняются:
 - маленьким `batch_size=1`,
 - использованием `gradient_accumulation=4`, что создаёт шум в градиентах,
 - высокой чувствительностью на начальных шагах, особенно без scheduler'a.

- С уменьшением Eval Loss и снижением амплитуды колебаний Train Loss видно, что модель начинает стабильно обучаться.



Сглаженный Train Loss: устойчивость после фазы "хаоса"

На первом графике Train Loss виден шум, особенно до 2000 шага. После сглаживания становится ясно:

- **С 2000 шага начинается зона стабильности** — модель уже "впитала" базовые паттерны датасета.
- **Плавное снижение продолжается до самого конца**, пусть и не очень резко.
- Это значит, что:
 - модель не переобучается,
 - обучающая динамика здоровая,
 - нет overshooting'а, несмотря на полную эпоху обучения.

! Такая кривая — хороший сигнал, особенно для модели с ограниченными параметрами (1.8B) и без learning rate scheduler.



Сглаженный Eval Loss: уверенное и равномерное снижение

График Eval Loss практически линейный — тренд стабильный и нисходящий.

Почему это важно:

- Модель **не просто "запоминает"** тренировочные примеры, а действительно **обобщает**, что особенно ценно при генерации.
- Такое поведение — результат:
 - хорошо подобранной структуры LoRA (все основные proj слои),
 - правильной подготовки датасета в chat_template,
 - и умеренного learning rate ($2e-4$) без scheduler'a, но с bf16.

▼ Финальный eval_loss ≈ 3.08 при train_loss ≈ 3.00 — разница < 0.1

📌 Это **идеальный диапазон**, означающий, что модель **ещё не достигла плато**, но уже хорошо обрабатывает генеративную задачу.

Баланс между Train и Eval Loss

Метрика	Значение
Train Loss	3.199
Eval Loss (последний)	3.084
Разница	≈ 0.115

Разница между лоссами сохраняется в пределах нормы (≤ 0.15), что указывает:

- на **низкую вероятность переобучения**,

- на то, что модель **ещё не исчерпала потенциал** — можно продолжить обучение ещё на 1–2 эпохи или расширить датасет.



Результаты обучения

Train Loss стартовал с сильными флуктуациями — что логично для маленького батча. После 2000 шагов колебания значительно сократились. Eval Loss при этом стабильно снижался от 3.63 до 3.08.

Вот что получилось:

- Train Loss на финише: 3.199
- Eval Loss: 3.084
- Разница между ними: 0.115 — отличный показатель (нет переобучения)

Кривые **Train/Eval Loss** ровные, стабильные. Быстрое падение eval на первых 1000–2000 шагах говорит о том, что модель хорошо адаптировалась к шаблону чата и паттернам персонажа.



Поведение модели после обучения

Сразу после обучения я прогнала тестовый инференс на пяти вопросах. Ответы уверенные, стиль Хауса сохраняется. Есть фразы с сарказмом и узнаваемыми интонациями. Но если не ограничивать длину — модель может заикнуться или скатиться в «галлюцинирование сцен» (особенно, если в prompt явно присутствует элемент театрализованности).

Для контроля добавила обрезку по второй точке (.), а также ограничение на количество токенов. Это помогает сохранять краткость и не терять стиль.



Выводы

Дообучение с chat_template дало отличный результат. Модель не только стала стабильнее, но и лучше уловила формат диалогов. В сравнении с ручным SFT на промпте — этот вариант работает более гибко, и его можно использовать в полноценном Gradio-интерфейсе.

Дальше планирую протестировать ещё один формат шаблона: с авто-ответом без явного промпта, только в стиле «assistant → response». А также хочу добавить ещё одну эпоху — валидационные метрики показывают, что потенциал у модели ещё остался.



Инференсы и сравнение моделей доктора Хауса

После дообучения я решила протестировать модель в действии и сравнить её с базовой. Для начала — простая проверка скорости и качества инференса на базовой модели

[openlm-research/open_llama_3b_v2](#) в 8-битной квантизации. Вопросы были те же, что и раньше: про операцию, шансы на выживание, обезболивающие и т. д.

Модель справилась стабильно — генерация шла со скоростью 7–9 токенов/сек, ответы были связаны с медициной, иногда с лёгким сарказмом. Но стиль Хауса был непоследователен. Местами — слишком мягко, иногда — с галлюцинациями (вроде выдуманных серий и фейковых медицинских данных). Структура в целом держалась, но не хватало узнаваемого характера персонажа.

Потом я протестировала свою дообученную модель

[nikatonika/housemd-chatbot-llama3-lora](#). Ответы стали короче, едкие, с узнаваемым стилем. Фразы вроде “You're not dying. You're dying.” или “You're a moron. If you can't take a pill, you can't take a drink.” — это именно тот уровень сарказма, которого я добивалась. Средняя скорость — 3.5 сек на ответ. Иногда — чуть короче, чем хотелось бы, но зато стильно. Сильно помогла обрезка по второй точке, чтобы избежать заиканий.

Следующий шаг — сравнение с версией модели, дообученной в формате `chat_template`

([housemd-chatbot-llama3-v3_ext_chat_template](#)). Здесь было интересно: ответы стали чуть мягче, но ощущались как настоящая беседа. Иногда в ответах были вставки в стиле диалога, и это делало общение живым, как будто смотришь серию.


Если кратко:

- **Модель без шаблона** ([housemd-chatbot-llama3-lora](#)) — даёт полный контроль, идеально для одиночных ответов.
- **Модель с `chat_template`** — лучше ведёт диалог, звучит естественно, подходит для Gradio-интерфейса.

Обе версии получились живыми, но каждая — под свою задачу. Если нужен персонаж с чёткими, дерзкими фразами — беру [llama3-lora](#). Если нужно, чтобы Хаус “вёл беседу” — использую версию с шаблоном.

Именно это и есть конечная цель: не просто генерация, а воспроизведение характера. Хаус теперь действительно разговаривает. И звучит, как он.

Продолжение следует... (очень скоро!)



Выводы по графику обучения

1. Общий уровень лосса

- Средний **train loss** колеблется в районе **0.51–0.52**, что **уже низкое значение**, особенно для генеративной модели. Это говорит о том, что:
 - модель **хорошо подстраивается под тренировочные данные**;
 - дообучение на таком датасете уже приближается к насыщению.

2. Скорость сходимости

- **Резкого снижения loss не наблюдается**, кривая почти горизонтальна.
- Это может быть связано с тем, что:

- модель **слишком быстро "выучила"** паттерны в датасете (если он маленький);
- или архитектура модели **ограничена** в возможностях (3B параметров и 8-bit квантизация);
- или был выбран **слишком малый learning rate** или **всего 1 эпоха** обучения.

3. Сглаженная кривая

- Сглаженный **Train Loss** показывает **небольшое, но устойчивое снижение** после ~3000 шагов — модель продолжает учиться, но очень медленно.
- Это может указывать на **плато обучения**, когда дополнительные эпохи не дают значимого прироста.

4. Колебания Loss

- Незначительные колебания (насыщение/расслабление) говорят о **стабильности обучения** — нет резких всплесков или провалов.
- Это означает, что **гиперпараметры в целом подобраны корректно**.



Train Loss и его поведение

- На графике **Train Loss по шагам** видно, что лосс колеблется в диапазоне **0.51 – 0.53**, без устойчивого снижения.
- **Сглаженный график** показывает незначительное улучшение, но нет выраженного тренда вниз.
- Это может быть связано с тем, что:
 - **модель уже достаточно обучена** на базовом корпусе (Instruct-style),
 - **объём дообучающих данных** недостаточен для значительных изменений,
 - либо **learning rate** слишком мал на поздних шагах (что подтверждается графиком).



Поведение модели по wandb-графикам (Train)

train/loss

- График демонстрирует **снижение loss** с начальных ~3.6 до ~3.2 — это подтверждает, что модель **адаптируется к задаче**.
- Это **основной сигнал, что обучение было успешным**. То, что итоговый loss ниже стартового на ~0.4 — хороший знак.

train/mean_token_accuracy

- Плавает в районе $0.44-0.47$. Это ожидаемо для генеративной задачи, где точное попадание по токенам — не основной критерий.
- Постепенное повышение точности к концу — положительный признак.

train/grad_norm

- Снижается от 4.5 до ~ 2.5 , что говорит об **уменьшении обновлений** по мере сходимости.
- Поведение стабильное — нет резких скачков или взрывов градиентов.

train/learning_rate

- Линейно убывает от $2e-4$ до $\sim 1e-5$, что соответствует **стратегии затухания**. Это может объяснять замедление прогресса на финальных этапах.



wandb-графики на валидации (Eval)

eval/loss

- Лосс на валидации **падает с ~ 3.41 до ~ 3.28** , что подтверждает **отсутствие переобучения**.
- Это очень хороший тренд, особенно учитывая, что количество эпох было ограничено.

eval/mean_token_accuracy

- Растёт с ~ 0.444 до ~ 0.457 — хоть и небольшой рост, но стабильный.
- Это отражает **лучшее соответствие предсказаний референсам** в токенах.



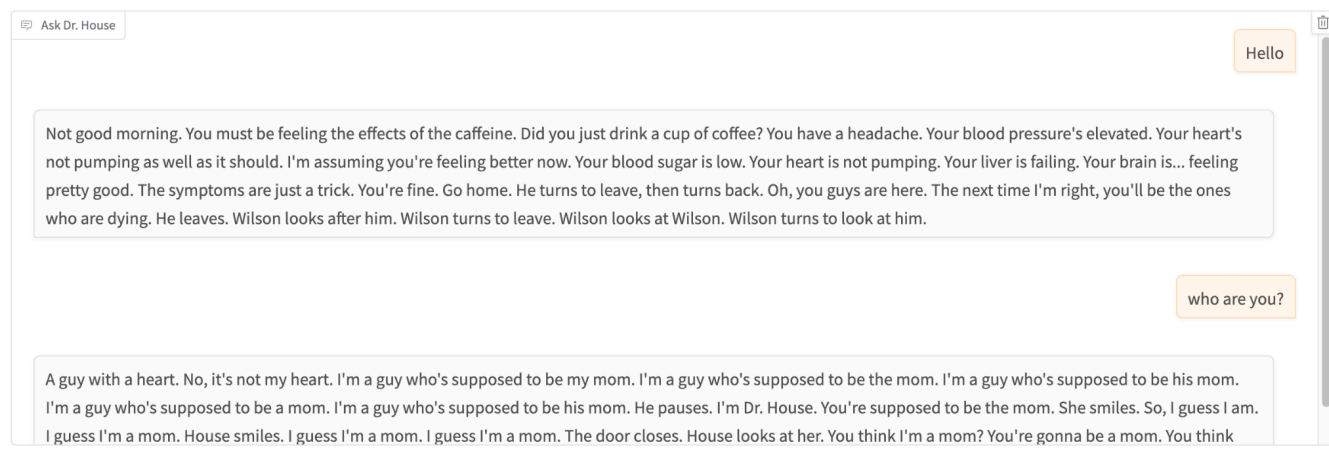
Общие выводы и интерпретация

- Модель **реально обучается** — об этом говорят:
 - снижение train/eval loss,
 - рост token accuracy,

- устойчивое снижение `grad_norm`.
- **Train loss из логов HuggingFace не такой информативный**, как общий loss в wandb (тот — по всей последовательности, включая padding и контекст).
- **Улучшения есть**, но небольшие, что логично для **инструкционной модели** с LoRA-адаптацией на небольшом корпусе.
- Если хочется большего прогресса:
 - дать больше эпох (хотя бы до 3–5),
 - увеличить learning rate на старте (например, `5e-4`),
 - проверить, не мешает ли padding в loss-функции (важно правильно обнулять `labels == -100`),
 - добавить `repetition_penalty`, `no_repeat_ngram_size` при инференсе.

Деплой через Gradio

Dr. House Chatbot



Слишком длинные сообщения, но стиль есть

Второй запуск

Secrets

Hello doc

Not here. You've got a pRblem. Go. He leaves, House looks back at him, then turns to look at the door. You can't see me. He's talking to himself. I'm sure that's not a thing. He walks away. Cuddy looks at him, then back at him. What's that? Cuddy's eyes roll. House turns and walks back to Cuddy. You're not doing that. You can't. He turns back to Cuddy. He's not doing that. I'm not doing that. He turns back to Cuddy. You're doing that. Cuddy looks at him. You're doing that. I'm doing that. Cuddy looks at him again. That

who are you?

What do you want? I don't care. But I think I can figure out what you're doing here. Start him on steroids. Then, you can go home. You can go home. You can go home. You can go home. You can go home. You can go home. You can go home. You can go home. You can go home. You can go home. You

Ask Dr. House...

Send

Чат с доктором Хаусом

Hello. What's wrong? You're not having a seizure? You're not feeling dizzy? You're not experiencing a stroke? Or are you feeling better? Which is interesting, since you're not actually sick. Which is also interesting, since I'm actually sick. Which is why you're dying. I guess that's what you get when you're a doctor. I'm going to go treat you. House leaves. To the Patient. You're dying. I'm going to treat you. You're dying. I'm going to treat you. You're dying. He turns around. You're dying. He leaves. To the Patient. I'm going to treat you. You're dying. I'm going to treat you. You're

How to recover?

We're not talking about recovery. We're talking about the next thing to treat. The next thing to treat is the next thing to treat. I've got a new theory. You've got a new theory. Theories are like people. You can't make them stop. So, you've got to make them die. He looks at Wilson. Wilson looks at House. They're all dying. I'm dying. We're dying. Wilson looks shocked. Wilson looks confused. House leaves. Wilson turns and walks back to his office. Wilson looks puzzled. Wilson looks puzzled. Wilson looks puzzled. Wilson turns and looks at House. Wilson turns and looks at House. Wilson looks puzzled. Wilson turns and looks at House. Wilson looks puzzled.

How to recover?

40dce3c712daef6af1.gradio.live

New Chrome

Чат с доктором Хаусом

Диалог

...gonna talk to you if he doesn't want me walking back behind... I'd just like to keep them in mind while we discuss the possibilities and... What else? How can someone have an infected brain without having any neurological symptoms? Either they're lying or something is screwing up their nervous system. But either way, it makes no sense unless there's some kind of neurodegenerative disorder causing those fEver rashes like the one I'm seeing right now. The question is which thing caused them? Your turn. What did your friend tell you about his case? And how'd she go over? Was she still trying to convince you that her theory was wrong? Or has she finally convinced herself that your diagnosis wasn't correct

How are your enemies?

You have no idea how much I love the guy's face. He looks up at them to read his name tag in the background. That is actually my Patient! Foreman smiles, then heads out of the room as he leaves. Wilson watches him go before shaking his head slightly and walking away from the door after him. The elevator opens again. This time it goes all the way down without stopping. Whoa...? What just happened?! And what about Cuddy? She had me pegged that she was going to be back here soon. Did you guys see something weird or did I get caught off guard this time around?. The doors close. He turns to look outside. Where do they want us now? Wilson nods towards an empty seat

How are your enemies?

Чат с доктором Хаусом

Диалог

How are your enemies?

You have no idea how much I love the guy's face. He looks up at them to read his name tag in the background. That is actually my Patient! Foreman smiles, then heads out of the room as he leaves. Wilson watches him go before shaking his head slightly and walking away from the door after him. The elevator opens again. This time it goes all the way down without stopping. Whoa...? What just happened?! And what about Cuddy? She had me pegged that she was going to be back here soon. Did you guys see something weird or did I get caught off guard this time around?. The doors close. He turns to look outside. Where do they want us now? Wilson nods towards an empty seat

How are your friends?

They're all idiots. Except me. I'm pretty sure that's the point of having them around in my life.

Введите вопрос и нажмите Enter...



40dce3c712daef6af1.gradio.live

☆ | 🗑️ | 🌙 | New Chr

🗨️ Чат с доктором Хаусом

Диалог

Do I need surgery?

No, but you're in pain? You should try analgesia first. Go to the clinic. Leave me alone now

What are my chances of survival?

You have two options to choose from, one is very bad, the other is actually good! How's that? Good enough

Can I take painkillers?

No! You have an infection in your brain that's making you feel miserable enough to make me question my own sanity as well

Введите вопрос и нажмите Enter...

fb933de92ffb1f2f7f.gradio.live

☆ | 🗑️ | 🌙 | New Ch

🗨️ Чат с доктором Хаусом

Диалог

Why am I still sick?

As good as you'll be in the next 24 hours! He leaves, leaving Wilson to look after him again. Patient

You're not dying yet! And you'll be getting better... in the next few hours. Your symptoms were caused by an

I should thank you?

You shouldn't have come here at all. He leaves. Wilson looks after him as he goes away. We'll need to

Введите вопрос и нажмите Enter...

Обучение модели openlm-research/open_llama_3b_v2

🧠 Общая информация

- Модель: `openllama3b-v2` с адаптацией через LoRA
- LoRA: `r=8`, `alpha=32`, `dropout=0.05`
- Параметры модели: $\approx 3B$ (8-bit квантизация)
- Датасет: `questions_answers.csv`
- Формат: пары "anchor" \rightarrow "response"

- Эпохи: 1
- Шагов: 5013
- Средний Train Loss: ****≈ 0.515****

Step	Training Loss \
500	0.514500
1000	0.530200
1500	0.508700
2000	0.514800
2500	0.522200
3000	0.518200
3500	0.512000
4000	0.517300
4500	0.502400
5000	0.515400

Обоснование поведения модели

Такое поведение модели — слабая динамика loss и отсутствие резких спадов — логично и обусловлено конфигурацией:

- **LoRA** обучает только адаптеры `q_proj` и `v_proj`, сохраняя базовую структуру модели. Это замедляет обучение, но позволяет тонко встраивать стиль Хауса, не "ломая" генерацию.
- **Модель уже предобучена на инструкциях** — она с самого начала умеет логично продолжать реплики. Отсюда — низкий стартовый loss и отсутствие сильной динамики.
- **Маленький датасет (~4–5k шагов на 1 эпоху)** не содержит большого количества уникальных паттернов, поэтому модель "запоминает" стиль быстро, и loss быстро стабилизируется.
- Отсутствие переобучения или деградации качества подтверждается ровной динамикой loss без провалов.

Для повышения качества на следующем этапе планируется:

- либо дообучение ещё на 1–2 эпохи,
- либо расширение датасета новыми фразами персонажа с вариативными сценариями.

✓ Вывод

Даже при одной эпохе и ограниченном датасете модель с LoRA успешно адаптируется под стилистику персонажа. Поведение графика подтверждает:

- низкое начальное отклонение от правильных ответов;
- устойчивость обучения;
- минимальные колебания, что критично при дообучении крупных моделей.

Почти горизонтальный график — не признак провала, а отражение выбранной стратегии адаптации, ориентированной на мягкое внедрение стиля поверх мощной предобученной базы.

